

Επεξεργασία Δεδομένων και Αλγόριθμοι Μάθησης

1^ο Σετ Ασκήσεων

Πρόβλημα 1: Έστω τυχαίο διάνυσμα $X = [x_1, x_2]$ μήκους 2 για το οποίο έχουμε τις εξής δύο υποθέσεις:

H_0 : x_1, x_2 είναι ανεξάρτητα με πυκνότητα πιθανότητας $f_0(x_1, x_2) = f_0(x_1)f_0(x_2)$ όπου $f_0(x) \sim \mathcal{N}(0, 1)$.

H_1 : x_1, x_2 είναι ανεξάρτητα με πυκνότητα πιθανότητας $f_1(x_1, x_2) = f_1(x_1)f_1(x_2)$ όπου $f_1(x) \sim 0.5\{\mathcal{N}(-1, 1) + \mathcal{N}(1, 1)\}$.

Υποθέστε ότι οι δύο αρχικές πιθανότητες $P(H_0) = P(H_1) = 0.5$. α) Ποιό είναι το βέλτιστο τεστ κατά Bayes που ελαχιστοποιεί την πιθανότητα σφάλματος απόφασης; β) Για να υπολογίσετε την πιθανότητα σφάλματος θα χρησιμοποιήσετε simulations. Δημιουργείστε 10^6 ζευγάρια $[x_1, x_2]$ από την $f_0(x_1, x_2)$ και άλλα 10^6 ζευγάρια από την $f_1(x_1, x_2)$. Όσον αφορά στην $f_1(x)$ με πιθανότητα 0.5 το δείγμα έχει μέσο όρο -1 και με πιθανότητα 0.5 μέσο όρο 1. Αφού δημιουργήσετε τις δύο κατηγορίες δειγμάτων θα εφαρμόσετε τον κανόνα Bayes και θα μετρήσετε τα ποσοστά των λάνθασμένων αποφάσεων στις δύο περιπτώσεις και θα τα αθροίσετε ώστε να βρείτε το τελικό αθροιστικό ποσοστό σφάλματος. Αυτό είναι το βέλτιστο ποσοστό που δεν μπορεί να το ξεπεράσει καμία άλλη μέθοδος.

γ) Τα ζευγάρια που δημιουργήσατε πριν, να τα διατηρήσετε γιατί θα τα χρησιμοποιήσετε στο ερώτημα αυτό. Δημιουργείστε επιπλέον 200 ζευγάρια από κάθε υπόθεση για να τα χρησιμοποιήσετε για την εκπαίδευση νευρωνικών δικτύων. Ενδιαφερόμαστε για πλήρη νευρωνικά δίκτυα διαστάσεων $2 \times 20 \times 1$ (είσοδος μεγέθους 2, κρυφό επίπεδο μεγέθους 20 και μία έξοδος) τα οποία εκτιμούν κάποιο γνωστό μετασχηματισμό του λόγου πιθανοφάνειας $r(x_1, x_2) = \frac{f_1(x_1) f_1(x_2)}{f_0(x_1) f_0(x_2)}$. Συγκεκριμένα θα εφαρμόσουμε 1) την cross-entropy μέθοδο με $\phi(z) = -\log(1 - z)$, $\psi(z) = \log(z)$ η οποία, όπως εξηγήσαμε, εκτιμά την εκ των υστέρων πιθανότητα $\frac{r(x_1, x_2)}{1+r(x_1, x_2)}$ και 2) την exponential με $\phi(z) = e^{0.5z}$, $\psi(z) = e^{-0.5z}$ η οποία εκτιμά το λογάριθμο $\log r(x_1, x_2)$. Χρησιμοποιείτε τα 200+200 δεδομένα εκπαίδευσης (training data) για να εκπαιδεύσετε τα δύο νευρωνικά δίκτυα εφαρμόζοντας τον stochastic gradient descent. Όταν τελειώνουν τα δεδομένα εκπαίδευσης τα επαναχρησιμοποιείτε από τη αρχή έως ότου συγκλίνει ο αλγόριθμος. Τη σύγκλιση μπορείτε να τη διαπιστώσετε παρακολουθώντας τις τιμές του κόστους $\phi(u(x_{1,t}^0, x_{2,t}^0, \theta_t)) + \psi(u(x_{1,t}^1, x_{2,t}^1, \theta_t))$ αφού το εξομαλύνετε υπολογίζοντας τον μέσο όρο των τελευταίων 20 τιμών. Στην περίπτωση του cross-entropy θα πρέπει στην έξοδο του δικτύου να εφαρμόσετε, όπως έχουμε εξηγήσει, μια μη γραμμικότητα ώστε η τιμή της εξόδου να είναι στο διάστημα $[0, 1]$ στο οποίο βρίσκεται η τιμή της εκ των υστέρων πιθανότητας. Στην περίπτωση του exponential κάτι αντίστοιχο δεν είναι απαραίτητο γιατί το exponential εκτιμά το λογάριθμο του λόγου πιθανοφάνειας που είναι οποιοσδήποτε πραγματικός θετικός ή αρνητικός. Όταν θα έχουν συγκλίνει οι δύο αλγόριθμοι τότε θα πάρετε τα δύο νευρωνικά δίκτυα και θα τα εφαρμόσετε στα $10^6 + 10^6$ δεδομένα που έχετε από το ερώτημα β) για να διαπιστώσετε τι ποσοστά λάθους κάνουν στην απόφαση. Θυμόμαστε ότι το τεστ του λόγου πιθανοφάνειας αποφασίζει υπέρ του H_1 όταν $r(x_1, x_2) > 1$ και υπέρ του H_0 όταν $r(x_1, x_2) < 1$. Εάν εφαρμόσετε τον λογάριθμο τότε θα συγκρίνετε το $\log r(x_1, x_2)$ με το 0, ενώ αν εφαρμόσετε την εκ των υστέρων πιθανότητα $\frac{r(x_1, x_2)}{1+r(x_1, x_2)}$ θα την συγκρίνετε με το 0.5. Το $\log r(x_1, x_2)$ το προσεγγίζει το νευρωνικό δίκτυο του exponential και το $\frac{r(x_1, x_2)}{1+r(x_1, x_2)}$ το νευρωνικό δίκτυο του cross-entropy. Πώς συγκρίνονται τα συνολικά σφάλματα των δύο μεθόδων με το βέλτιστο σφάλμα της μεθόδου Bayes;

Πρόβλημα 2: Εφαρμόστε την ιδέα του ερωτήματος γ) του Προβλήματος 1 στα δεδομένα της βιβλιοθήκης MNIST. Απομονώστε τα νούμερα 0 και 8 και δημιουργείστε classifier που διακρίνει μεταξύ των δύο αριθμών χρησιμοποιώντας νευρωνικό δίκτυο που το εκπαιδεύετε με α) Hinge, β) Cross-entropy και γ) Exponential. Η MNIST έχει 5500 εικόνες διαστάσεων 28×28 σε αποχρώσεις του γκρι για training. Χρησιμοποιείτε πλήρες νευρωνικό δίκτυο διαστάσεων $784 \times 300 \times 1$ ($784 = 28 \cdot 28$ εισόδους, δηλαδή οι εικόνες θα γίνονται διανύσματα!, 300 κρυφό επίπεδο και 1 έξοδος). Φροντίστε τα pixel των εικόνων να έχουν τιμές στο διάστημα $[0, 1]$. Αν τα επίπεδα του γκρι είναι μεταξύ $[0, 255]$ διαιρέστε τις τιμές τους με 255. Η MNIST διαθέτει επίσης επιπλέον εικόνες για testing. Για κάθε νούμερο ο αριθμός των εικόνων αυτών είναι διαφορετικός. Όταν σχεδιάσετε τα νευρωνικά δίκτυα με τα training δεδομένα μετά τα εφαρμόζετε στα testing προκειμένου να δείτε τα ποσοστά σφαλμάτων. Κάντε ένα πίνακα που για κάθε μέθοδο θα δίνει την πιθανότητα σφάλματος ανά υπόθεση καθώς και το συνολικό ποσοστό σφάλματος.

Παρατηρήσεις: Η αρχικοποίηση των παραμέτρων των νευρωνικών δικτύων πρέπει να γίνει ως εξής: Τα offset θα τα ξεκινάτε με 0. Κάθε επίπεδο έχει μια μήτρα βαρών w που με διαστάσεων $m \times n$. Τα στοιχεία της μήτρας θα τα επιλέγετε τυχαία, Gaussian με μέση τιμή 0 και διασπορά $\frac{1}{n+m}$.